

<i>Autor/Autorzy</i>	Patryk Chmielak, 420666; Mateusz Kotermański, 474686
<i>Który temat?</i>	Dane panelowe
<i>Wykorzystanie SI</i>	<i>Podczas przygotowania tej pracy autorzy użyli Google NotebookLM w celu sprawniejszego przeglądu materiałów. Autorzy pracy dokonali weryfikacji treści i redakcji tekstu pracy zgodnie z jej założeniami, prezentują własny wkład intelektualny i biorą pełną odpowiedzialność za ostateczną postać pracy.</i>

Informacje o artykule będącym inspiracją dla minimodelu

<i>Tytuł</i>	Institutions and Growth: A GMM/IV Panel VAR Approach
<i>Autor/Autorzy</i>	Carlos Góes
<i>Journal/Miejsce publikacji</i>	Economics Letters 138 / IMF Working Paper 15/174
<i>Rok</i>	2016 (journal) / 2015 (working paper)
<i>Zakres stron</i>	85-91
<i>Tematyka, problemy i cele badawcze</i>	Artykuł zmierzył się z jednym z najstarszych problemów ekonomii rozwoju: czy dobre instytucje prowadzą do wzrostu, czy też bogactwo pozwala budować lepsze instytucje? Wyniki badania przemawiają za wyższością instytucji nad geografiami w procesie rozwoju gospodarczego. Autor wykorzystuje metodę panelową do rozstrzygnięcia problemu endogeniczności.
<i>Główne wnioski</i>	Szok w jakości instytucji o 1% prowadzi do szczytowego wzrostu PKB per capita o 1,7% po 6 latach. Efekt jest istotny statystycznie do 10 lat. Występuje heterogeniczność: kraje rozwinięte reagują słabiej, kraje rozwijające się silniej, co sugeruje malejące korzyści krańcowe z reform instytucjonalnych. Wyniki potwierdzają przyczynowość między instytucjami a wzrostem.
<i>Metodyka badawcza</i>	Panel Structural VAR - system 2 równań endogenicznych. Estymacja: GMM Arellano-Bond dla paneli dynamicznych z transformacją pierwszych różnic. Identyfikacja strukturalna: dekompozycja Cholesky'ego z założeniem, że instytucje nie wpływają natychmiastowo na PKB. Funkcje reakcji na impuls (IRF) z przedziałami ufności 90% obliczanymi metodą bootstrap przekrojowego (1000 iteracji, wykluczanie 10 krajów w każdej iteracji).
<i>Dane</i>	PKB per capita z World Development Indicators oraz Economic Freedom of the World Index z Fraser Institute. Okres 2000-2012, 119 krajów, 1190 obserwacji.
<i>Dlaczego wybrano właśnie ten artykuł?</i>	(1) Ponieważ zawiera pełny panel SVAR z IRF - ciekawy temat. (2) Dobrze udokumentowana metodologia z równaniami i algorytmem bootstrap w aneksie (working paper, badanie właściwe nie ma tego aneksu). (3) Prosty system oparty na 2 zmiennych - wykonalny jako minimodel przy ograniczonych zasobach czasowych i intelektualnych. (4) Dane publicznie dostępne (zarówno WDI, jak i Fraser Institute). (5) Dostępny kod źródłowy autora z EViews na GitHub - umożliwia szczegółową weryfikację implementacji 'side-by-side'.

Podstawowe informacje o minimodelu

<i>Tytuł minimodelu</i>	Instytucje a wzrost gospodarczy: replikacja i rozszerzenie analizy 'Panel SVAR' z wykorzystaniem danych 2000-2022
<i>Tematyka, problemy i cele badawcze</i>	Postanowiliśmy sprawdzić, czy wyniki Góesa utrzymują się na nowszych danych. Replikujemy jego podejście w trzech okresach: oryginalnym (2000-2012), rozszerzonym (2000-2022) i post-kryzysowym (2012-2022). Główna hipoteza jest prosta: pozytywny szok w jakości instytucji powinien prowadzić do wzrostu PKB.
<i>Metodyka badawcza</i>	Panel SVAR z 2 zmiennymi, estymacja GMM Arellano-Bond w pierwszych różnicach (pakiet 'plm::pgmm' w R). Identyfikacja Cholesky'ego z kolejnością [log_PKB, log_EFW]. Bootstrap przekrojowy (1000 iteracji, 10 krajów wykluczanych) dla przedziałów ufności 90%.
<i>Dane</i>	Dane panelowe z World Development Indicators (PKB per capita, kod: NY.GDP.PCAP.KD) oraz Fraser Institute (Economic Freedom of the World Index, edycja 2025). N krajów: 157 (2000-2012), 156 (2000-2022), 160 (2012-2022). Zmienne: log(PKB per capita), log(EFW index).
<i>Główne wnioski</i>	Dla okresu bazowego (2000-2012) uzyskano IRF = +0,69% (podczas gdy Góes +1,70%), potwierdzając pozytywny i istotny statystycznie wpływ instytucji na wzrost. Ale gdy rozszerzyliśmy próbę do 2022 - relacja się odwróciła. Dla okresu pokryzysowego (2012-2022) IRF = -1,35%. Szok w jakości instytucji prowadzi teraz do spadku PKB. To albo zmiana w mechanizmie transmisji, albo Economic Freedom of the World Index nie pozwala jednak śledzić opisywanych zjawisk.

Wprowadzenie

Pytanie o źródła wzrostu gospodarczego to jeden z najstarszych problemów ekonomii. W XX wieku dominowały modele akumulacji kapitału (Solow, 1956) i kapitału ludzkiego (Lucas, 1988), jednak pod koniec stulecia uwaga przesunęła się ku czynnikom instytucjonalnym. Prace Douglassa Northa (1990) i Darona Acemoglu, Simona Johnsona i Jamesa A. Robinsona (2001) sprawiły, że hipoteza instytucjonalna - że jakość instytucji jest kluczową determinantą rozwoju - zyskała szeroką akceptację. Ale jest jeden szkopuł: endogeniczność.

Można sobie wyobrazić dwa scenariusze: (A) dobre instytucje prowadzą do wzrostu, bo chronią własność, egzekwują kontrakty, ograniczają korupcję; (B) bogactwo pozwala budować lepsze instytucje, bo zamożne społeczeństwa mają zasoby na sprawne sądy, policję, administrację. Który scenariusz jest prawdziwy? Prawdopodobnie oba - ale w jakich proporcjach?

Góes (2016) zaproponował alternatywne podejście do testowania hipotezy instytucjonalnej. Zamiast szukać zewnętrznego instrumentu, wykorzystał strukturę dynamiczną modelu Panel VAR. Ta metodologia pozwala na:

- kontrolę endogeniczności przez użycie opóźnionych wartości jako instrumentów;
- usunięcie efektów stałych poszczególnych krajów poprzez różnicowanie;
- śledzenie dynamiki zależności w czasie przez funkcje reakcji na impuls.

Ekonometryczny opis badania

Vector Autoregression (VAR) to elegancka idea: zamiast decydować z góry, która zmienna jest „zależna” a która „niezależna”, traktujemy wszystkie symetrycznie. Każda zmienna jest regresowana na własne opóźnienia oraz opóźnienia wszystkich pozostałych. W wersji panelowej:

$$y_{i,t} = \mu_i + \Gamma_1 y_{i,t-1} + \Gamma_2 y_{i,t-2} + \dots + \Gamma_p y_{i,t-p} + e_{i,t}$$

gdzie $y_{i,t}$ to wektor zmiennych dla kraju i w czasie t , μ_i to efekty stałe (każdy kraj ma swój "poziom bazowy"), Γ_j to macierze współczynników, a $e_{i,t}$ to reszty.

W przypadku Góesa (2016) system jest minimalistyczny - tylko dwie zmienne:

$$y_{i,t} = \begin{bmatrix} c_{i,t} \\ k_{i,t} \end{bmatrix}$$

gdzie $c_{i,t} = \log(\text{"PKB per capita"})$ i $k_{i,t} = \log(\text{"EFW index"})$. Interpretacja w kontekście VAR jest intuicyjna: patrzymy, jak PKB i instytucje wzajemnie na siebie wpływają z opóźnieniem.

Problem efektów stałych

W standardowym modelu panelowym z efektami stałymi OLS daje obciążone wyniki. Dlaczego? Zaczniemy od prostszego przypadku jednej zmiennej:

$$y_{i,t} = \alpha_i + \beta y_{i,t-1} + \epsilon_{i,t}$$

Transformacja within (odejmowanie średnich grupowych) nie eliminuje korelacji między przekształconą zmienną objaśniającą a przekształconym błędem. To tzw. Nickell bias - i jest tym większy, im krótszy panel. Rozwiązanie Arellano-Bond: Zamiast within transformation, zastosowanie pierwszych różnic eliminuje efekty stałe:

$$\Delta y_{i,t} = \beta \Delta y_{i,t-1} + \Delta \epsilon_{i,t}$$

Jednak $\Delta y_{i,t-1}$ jest skorelowane z $\Delta \epsilon_{i,t}$ przez $\epsilon_{i,t-1}$. Rozwiązaniem jest użycie $y_{i,t-2}$ i wcześniejszych poziomów jako instrumentów, ponieważ:

$$E[y_{i,t-2} \cdot \Delta \epsilon_{i,t}] = E[y_{i,t-2} \cdot (\epsilon_{i,t} - \epsilon_{i,t-1})] = 0$$

przy założeniu braku autokorelacji reszt.

W naszym przypadku mamy dwie zmienne endogeniczne, więc model w pierwszych różnicach przyjmie postać:

$$\begin{cases} \Delta c_{i,t} = \gamma_{11} \Delta c_{i,t-1} + \gamma_{12} \Delta k_{i,t-1} + e_{1,i,t} \\ \Delta k_{i,t} = \gamma_{21} \Delta c_{i,t-1} + \gamma_{22} \Delta k_{i,t-1} + e_{2,i,t} \end{cases}$$

Powyższe informacje wystarczą, żeby przejść do wyprowadzenia podstawowego modelu z badania.

Zaczynamy od zapisania modelu w surowej postaci - dla wartości zmiennych, nie ich zmian:

$$y_{i,t} = \mu_i + \Gamma y_{i,t-1} + e_{i,t}$$

gdzie:

$y_{i,t} = [c_{i,t}, k_{i,t}]'$ - wektor zmiennych endogenicznych

$c_{i,t} = \log(\text{PKB per capita})$

$k_{i,t} = \log(\text{indeks instytucji EFW})$

μ_i - efekt stały dla kraju i

Γ - macierz współczynników autoregresji (2x2)

$e_{i,t}$ - wektor reszt formy zredukowanej

Logika instrumentów pozostaje taka sama: używamy $c_{i,t-2}, c_{i,t-3}, \dots$ oraz $k_{i,t-2}, k_{i,t-3}, \dots$ jako instrumentów dla zróżnicowanych opóźnionych zmiennych. Tak skonstruowany system możemy zapisać w formie macierzowej:

$$\begin{aligned} \Delta y_{i,t} &= \Gamma \cdot \Delta y_{i,t-1} + e_{i,t} \\ &\quad \downarrow \\ \Gamma &= \begin{bmatrix} \gamma_{11} & \gamma_{12} \\ \gamma_{21} & \gamma_{22} \end{bmatrix} \end{aligned}$$

gdzie:

γ_{11} - jak bardzo wzrost PKB "utrzymuje się" z roku na rok

γ_{12} - wpływ opóźnionej zmiany instytucji na bieżący wzrost PKB

γ_{21} - wpływ opóźnionego wzrostu PKB na bieżącą zmianę instytucji

γ_{22} - jak bardzo zmiany instytucji "utrzymują się" z roku na rok.

GMM - minimalizacja warunków momentowych

Estymacja GMM opiera się na warunkach momentowych - założeniach o tym, jakie korelacje powinny wynosić zero, gdybyśmy dysponowali nieskończenie dużą próbą. W naszym przypadku zakładamy, że instrumenty (wartości zmiennych sprzed dwóch i więcej okresów) nie są skorelowane z bieżącymi resztami:

$$E[\Delta e_{i,t} \cdot y_{i,t-s}] = 0 \text{ dla } s \geq 2$$

W rzeczywistej próbie ta korelacja nie wyjdzie dokładnie zero, ale powinna być bliska zeru. Estymator GMM szuka takich wartości parametrów Γ , które minimalizują odchylenia od tych teoretycznych zer - formalnie minimalizuje $g(\Gamma)'Wg(\Gamma)$, gdzie $g(\Gamma)$ to wektor warunków momentowych, a W to macierz wag. I tu ważna uwaga: używamy wersji one-step. To odpowiada opcji 'gmm=2sls' w EViews, której Góes użył w swoim kodzie. Nazwa '2SLS' jest myląca - nie chodzi o dwustopniowy GMM, tylko o two-stage least squares, co jest odpowiednikiem one-step GMM.

W R używamy 'plm::pgmm' z 'model=onestep' i 'transformation=d'. Różnica: nasz 'pgmm' instrumentuje opóźnionymi poziomami (log), Góes opóźnionymi różnicami (dlog). Wpływ tej różnicy zbadaliśmy w benchmarku w dalszej części pracy.

Identyfikacja strukturalna - dekompozycja Cholesky'ego

Estymacja VAR daje nam reszty $e_{i,t}$ które są wzajemnie skorelowane - szok w PKB „miesza się” z szokiem w instytucjach. By mówić o przyczynowości (np. 'szok w instytucjach powoduje wzrost PKB'), musimy wyodrębnić szoki strukturalne $u_{i,t}$ które są ortogonalne (nieskorelowane ze sobą).

Związek między resztami a szokami strukturalnymi:

$$e_{i,t} = Bu_{i,t}$$

gdzie B to macierz przekształcenia. Szukamy takiego B , żeby macierz kowariancji reszt dała się rozłożyć jako:

$$\Sigma_e = E[e_{i,t}e'_{i,t}] = BB'$$

Dekompozycja Cholesky'ego znajduje dolną trójkątną macierz B spełniającą ten warunek:

$$B = \begin{bmatrix} b_{11} & 0 \\ b_{21} & b_{22} \end{bmatrix}$$

Zero w prawym górnym rogu to restrykcja identyfikująca: druga zmienna nie wpływa na pierwszą zmienną w tym samym roku. Kolejność zmiennych w wektorze y determinuje, która zmienna jest 'pierwsza' (może reagować tylko z opóźnieniem na szoki w drugiej). U nas: $y = [c, k]' = [\log PKB, \log EFW]'$, więc instytucje nie wpływają na PKB w bieżącym okresie, ale PKB może w bieżącym okresie wpływać na instytucje.

Ta restrykcja jest konserwatywna dla hipotezy instytucjonalnej - zmniejsza szacowany krótkoterminowy wpływ instytucji. Jak pisze Góes (2016, s. 86): "this design is more robust if one is trying to test the institutional hypothesis". W naszym przypadku dla okresu 2000-2012:

$$y_{i,t} = \begin{bmatrix} PKB \\ EFW \end{bmatrix} \rightarrow B = \begin{bmatrix} b_{11} & 0 \\ b_{21} & b_{22} \end{bmatrix} = \begin{bmatrix} 0.0522 & 0 \\ 0.0117 & 0.0539 \end{bmatrix}$$

Zero w prawym górnym rogu oznacza: szok w instytucjach NIE wpływa na PKB w tym samym roku. Ekonomicznie: reformy instytucjonalne potrzebują czasu - efekt pojawia się dopiero w następnych okresach. Jeśli mimo tej restrykcji znajdziemy pozytywny efekt w późniejszych latach, wynik jest tym bardziej wiarygodny.

Funkcje reakcji na impuls (IRF)

Mając macierz B , możemy prześledzić jak szok w instytucjach propaguje się przez system w kolejnych latach. Funkcje reakcji na impuls pokazują, jak zmienne systemu reagują na jednostkowy szok strukturalny w jednej ze zmiennych.

Intuicja jest prosta: wyobraźmy sobie, że w roku 0 jakość instytucji nagle się poprawia (np. reforma sądownictwa). IRF odpowiada na pytanie: o ile procent wzrośnie PKB w roku 1? W roku 2? W roku 10? Czy efekt narasta, stabilizuje się, a może zanika? Wykres IRF to "ścieżka reakcji" rozłożona w czasie.

Żeby uzyskać opisywaną zależność, potrzebujemy macierzy przejścia Φ_h , które kumulują efekty auto-regresji przez kolejne okresy. Startujemy od macierzy jednostkowej $\Phi_0 = I$, a każdy kolejny horyzont to $\Phi_h = \Gamma^h$. Tak wygląda odpowiedź PKB na szok w instytucjach:

$$IRF_{(PKB \leftarrow EFW)(h)} = (\Phi_h \cdot B)_{1,2}$$

$IRF_{(PKB \leftarrow EFW)(h)}$ - odpowiedź PKB na szok w instytucjach po h latach

Φ_h - macierz przejścia w horyzoncie h , czyli Γ^h

B - macierz dekompozycji Cholesky'ego

$(\dots)_{1,2}$ - element w pierwszym wierszu i drugiej kolumnie wyniku mnożenia (odpowiedź pierwszej zmiennej na szok w drugiej).

Bootstrap dla przedziałów ufności

Sama wartość IRF to za mało - potrzebujemy wiedzieć, czy wynik jest statystycznie istotny. Góes (2016) stosuje niestandardową procedurę bootstrap. Zamiast losować z reszt (klasyczny bootstrap), losuje które kraje wykluczyć z próby. Intuicja: sprawdzamy, czy wynik zależy od kilku konkretnych krajów, czy jest stabilny niezależnie od składu próby.

W artykule Góes podaje wzór na liczbę wykluczanych krajów: $k = \lfloor 0.1 \times N \rfloor + 1$. Dla $N=119$ daje to $k=12$, dla naszego $N=157$ dałoby $k=16$. Jednak w kodzie EViews na GitHubie autor używa stałej wartości 10, niezależnie od wielkości próby. W naszej implementacji przyjęliśmy tę samą wartość co w kodzie źródłowym - 10 krajów.

Procedura: powtarzamy 1000 razy losowanie 10 krajów do wykluczenia, estymację modelu na pozostałych i obliczenie IRF. Po 1000 powtórzeniach mamy rozkład IRF dla każdego horyzontu. Odchylenie standardowe tego rozkładu to błąd standardowy:

$$\sigma_{\rho(h)} = \sqrt{\text{Var}(IRF_{1(h)}, IRF_{2(h)}, \dots, IRF_{1000(h)})}$$

Po wykonaniu bootstrapu mamy dla każdego horyzontu h tysiąc wartości IRF - to jest nasz rozkład. Jego odchylenie standardowe to błąd standardowy $\sigma_{\rho(h)}$. Przedziały ufności 90% konstruujemy jako:

$$IRF(h) \pm 1.645 \times \sigma_{\rho(h)}$$

Jeśli przedział zawiera zero, nie możemy wykluczyć braku efektu. Jeśli cały przedział jest powyżej zera - mamy statystycznie istotny pozytywny wpływ instytucji na PKB.

Podsumowując wszystkie kroki: estymujemy system VAR metodą GMM Arellano-Bonda (by uniknąć Nickell bias), rozkładamy macierz kowariancji reszt dekompozycją Cholesky'ego (by zidentyfikować szoki strukturalne), obliczamy funkcje reakcji na impuls (by prześledzić efekt w czasie), a niepewność szacujemy bootstrapem przekrojowym (by sprawdzić stabilność wyniku). Mając te narzędzia, możemy przejść do danych i odpowiedzi na pytanie: czy poprawa instytucji rzeczywiście przekłada się na wzrost gospodarczy?

Dane

Badanie wykorzystuje dwa źródła danych łączone po kodzie kraju (ISO3) i roku:

Tabela 1. Źródła danych

Zmienna	Źródło	Kod/Identyfikator	URL
PKB per capita	World Development Indicators	NY.GDP.PCAP.KD	databank.worldbank.org
Indeks wolności gospodarczej (EFW)	Fraser Institute	EFW Summary Index	efotw.org

Źródło: opracowanie własne na podstawie wymienionych linków

PKB per capita: Użyliśmy wskaźnika NY.GDP.PCAP.KD z World Development Indicators (WDI) Banku Światowego. Jest to PKB per capita w stałych cenach USD z rokiem bazowym 2015. Góes (2016) używał roku bazowego 2005. Dla różnic względnych nie powinno to mieć znaczenia, natomiast należy uwzględnić możliwość, że publikowane wartości mogły być poddane rewizji.

Economic Freedom of the World (EFW): Indeks Fraser Institute mierzący jakość instytucji gospodarczych w 5 obszarach: rozmiar rządu, system prawny i prawa własności, stabilność monetarna, wolność handlu międzynarodowego, regulacje. Skala 0-10, wyższa wartość = lepsze instytucje. Użyliśmy edycji EFW 2025, podczas gdy Góes (2016) korzystał z edycji 2014.

Zachowaliśmy formułę panelu zbalansowanego, czyli taką strukturę, gdzie obserwujemy wiele jednostek (kraje) w wielu okresach (lata), gdy każda jednostka ma obserwacje dla dokładnie tych samych okresów - nie ma braków danych. Połączyliśmy dane WDI i EFW przez inner join po kodzie kraju (ISO3) i roku. Inner join oznacza, że zachowujemy tylko te obserwacje, które istnieją w obu źródłach. Następnie usunęliśmy kraje z jakimikolwiek brakami danych w analizowanym okresie. Z 219 krajów WDI i 165 krajów Fraser, po inner join i filtrowaniu braków, uzyskaliśmy 157 krajów.

Tabela 2. Statystyki opisowe dla okresu 2000-2012 (N=157)

Statystyka	PKB per capita (USD)	EFW Index
Minimum	243	2,25
1. kwartyl	1 372	5,66
Mediana	4 241	6,42
Średnia	12 497	6,41
3. kwartyl	16 146	7,32
Maksimum	112 418	9,20

Źródło: pakiet w R oraz dane EFW

Skoro omawiamy kwestię panelu zbalansowanego, warto z góry zanotować, jakie są różnice w obranych okresach - w aneksie będą przytoczone tylko kraje z próby replikacyjnej (2000-2012), ale dane WDI i Fraser Institute nie są jednolite w czasie, co obrazuje poniższa tabela:

Tabela 3. Struktura próby

Okres	Lata	N krajów	N obserwacji
Replikacja Góesa	2000-2012	157	2041
Rozszerzony	2000-2022	156	3588
Po kryzysie	2012-2022	160	1760

Źródło: opracowanie własne w R

Wyniki replikacji

Estymacja na danych 2000-2012 potwierdza wniosek Góesa: instytucje wpływają na wzrost PKB (γ_{12} istotne). Wielkość efektu jest mniejsza - szczytowy IRF = +0,69% vs +1,70% u Góesa. Trudno powiedzieć, skąd wynika różnica - może to być efekt nowszej edycji danych (WDI i Fraser dokonywały rewizji między edycjami), szerszej próby (157 vs 119 krajów - najwyraźniej dodatkowe kraje osłabiają relację) oraz różnic w implementacji funkcji (R vs EViews).

Trzeba podkreślić - badanie Góesa wskazuje na dwukierunkową zależność EFW z PKB, jednak w naszym badaniu γ_{21} uchodzi za nieistotne statystycznie, chociaż dość blisko progu istotności. Nauczeni doświadczeniem zachowujemy pewną rezerwę do p-value; kierunek zależności jest spójny z oryginalnym badaniem, więc na tym etapie replikacji nie uznajemy za nieudaną.

Tabela 4. Porównanie siły badanych efektów

Parametr	Góes (2016) EViews, N=119	Nasz R, WDI+Fraser N=157
γ_{12} (EFW -> PKB)	-	0,319 (p = 0,008)
γ_{21} (PKB -> EFW)	-	0,021 (p = 0,11)
szczytowy IRF (1% szok)	+1,70%	+0,69%
h (horyzont) szczytowego IRF	6	5

Źródło: opracowanie własne w R oraz Góes (2016)

Dokładna analiza porównawcza kodu EViews Góesa z kodem w R ujawniła różnicę w typie instrumentów. Góes podaje zmienne już zróżnicowane (dlog) i instrumentuje opóźnionymi różnicami. Nasz 'pgmm' instrumentuje opóźnionymi poziomami (log). Aby ocenić wpływ tej różnicy, przeprowadziliśmy benchmark dwóch specyfikacji na tych samych danych (2000-2012):

Tabela 5. Porównanie specyfikacji instrumentów

Model	γ_{12}	p-value	Statystyka F (IV/2SLS)
plm::pgmm	0,319	0,008	-
2SLS (Góes)	-0,808	0,378	1,36

Źródło: opracowanie własne w R

Sposób Góesa (opóźnione różnice) daje na naszych danych słabe instrumenty (F znacznie poniżej progu 10) i nieistotny γ_{12} . Standardowy Arellano-Bond w R z opóźnionymi poziomami daje wynik bliższy oryginałowi Góesa, nie dalszy. Różnica w typie instrumentów nie jest zatem wytrychem do osiągnięcia zgodności replikacji z badaniem - problem tkwi w czymś innym.

Pomimo oczywistych kandydatów do wytłumaczenia niezgodności, takich jak duża różnica w liczbie krajów między badaniami, trudno nie oprzeć się wrażeniu, że coś musimy liczyć źle. Skoro wybór nieidentycznej z oryginałem badania specyfikacji instrumentów jest niezbędny, żeby uzyskać ten sam kierunek efektu, a odwzorowanie opóźnionych różnic 2SLS spowodowało zmianę znaku, coś tu musi być krótko mówiąc nie tak - szczególnie że jawny dostęp do kodu Góesa z GitHuba umożliwia kontrolę, czy nie popełniliśmy pomyłki w algorytmach.

Dlatego w kolejnym kroku sprawdzimy rozszerzone okna czasowe - aby sprawdzić, co stanie się z wynikami w innych okresach.

Rozszerzenie okresu badania

Kluczowym wynikiem naszego rozszerzenia jest zmiana znaku relacji EFW -> GDP w czasie. W okresie bazowym 2000-2012 szacujemy $\gamma_{12} = +0,319$ ($p = 0,008$), znak pozostaje zgodny z Góesem (2016). Jednak w pełnym okresie 2000-2022 efekt zanika, a w podokresie 2012-2022 staje się silnie ujemny:

Tabela 6. Wyniki estymacji GMM - trzy okresy

Parametr	2000-2012 (N=157)	2000-2022 (N=156)	2012-2022 (N=160)
γ_{12} (EFW -> PKB)	0,319 ($p=0,008$)	-0,014 ($p=0,739$)	-0,757 ($p<0,001$)
γ_{21} (PKB -> EFW)	0,021 ($p=0,111$)	0,004 ($p=0,627$)	-0,080 ($p<0,001$)
γ_{11} (stałość PKB)	0,878 ($p<0,001$)	0,932 ($p<0,001$)	0,826 ($p<0,001$)
γ_{22} (stałość EFW)	0,729 ($p<0,001$)	0,811 ($p<0,001$)	0,628 ($p<0,001$)
p-value AR(2)	0,101	0,021	0,896
Test Sargana	$2,8 * 10^{-5}$	1,0	$1,7 * 10^{-8}$
szczytowy IRF	+0,69% ($h=5$)	-0,05% ($h=8$)	-1,35% ($h=6$)

Źródło: opracowanie własne w R

Jednoprocentowy wzrost EFW prowadzi w okresie 2012-2022 do spadku GDP o 1,35% w horyzoncie 6 lat. Jest to wynik wysoce istotny statystycznie zarówno punktowo ($p < 0,001$), jak i w procedurze bootstrap (będzie przedstawiona w kolejnej sekcji).

Diagnostyka wymaga zaś uczciwego komentarza: żaden z trzech badanych okresów nie przechodzi jednocześnie testu AR(2) i testu Sargana. Test AR(2) jest spełniony dla 2000-2012 ($p = 0,101$) i 2012-2022 ($p = 0,896$), ale odrzuca dla 2000-2022 ($p = 0,021$), co podważa specyfikację dla tego okresu. Z testem Sargana jest gorzej: odrzuca egzogeniczność instrumentów w okresach 2000-2012 i 2012-2022, a wartość $p = 1,000$ dla 2000-2022 jest podejrzanie idealna - przy $T = 23$ liczba instrumentów najwyraźniej rośnie na tyle, że test może po prostu tracić moc.

Bootstrap

Stabilność wyników zweryfikowaliśmy bootstrapem przekrojowym zgodnym z procedurą Góesa. W każdej z 1000 iteracji losowo wykluczamy 10 krajów, reestymujemy model, liczymy IRF. Przedziały ufności 90% liczymy dwoma sposobami: średnia $\pm 1,645 * SD$ (konwencja Góesa) i percentylowo (5. i 95. percentyl rozkładu bootstrap). Oba podejścia dają zbliżone wyniki, co wskazuje na w przybliżeniu normalny rozkład estymatora.


Tabela 7. Przedziały ufności bootstrapu - reakcja % PKB na 1% szok EFW

Okres	Szczytowy IRF	h (horyzont)	CI ($\pm 1,645 * SD$)	CI (percentyl)
2000-2012	+0,69%	5	[+0,58; +0,80]	[+0,58; +0,81]
2000-2022	-0,05%	8	[-0,13; +0,04]	[-0,13; +0,05]
2012-2022	-1,35%	6	[-1,71; -0,99]	[-1,70; -1,02]

Źródło: opracowanie własne w R

Bootstrap potwierdza wyniki estymacji punktowej. W 2000-2012 efekt istotny na 90% - dolna granica przedziału nie zawiera zera. W 2000-2022 żaden horyzont nie jest istotny. W 2012-2022 negatywny efekt jest istotny dla wszystkich horyzontów. Innymi słowy - odwrócenie znaku po 2012 nie jest tylko anomalią na skutek doboru kilku nietypowych krajów w próbie. Nawet po losowym usunięciu 10 z 160 krajów, w żadnej z 1000 iteracji przedział ufności nie objął zera.

Rysunek 1. Funkcje reakcji na impuls - reakcja % PKB na 1% szok EFW, z uwzględnieniem 90% CI



Źródło: opracowanie własne w R

Podsumowanie

Replikacja Góesa na nowszych danych (WDI 2025, EFW 2025) i szerszej próbie (157 vs 119 krajów) potwierdza główny wniosek oryginału: w okresie 2000–2012 wzrost wolności gospodarczej przekłada się na wzrost PKB. Głównym odkryciem jest niestabilność tej relacji w czasie - w rozszerzeniu do 2000-2022 efekt zanika, a w podokresie 2012-2022 odwraca się. Odwrócenie znaku po 2012 roku można interpretować na kilka sposobów, z których żaden nie jest w pełni satysfakcjonujący. Kilka obserwacji nasuwa się jednak naturalnie. Kryzys finansowy 2008-2009 uderzył nieproporcjonalnie w kraje o wysokim stopniu liberalizacji rynków finansowych. Pandemia COVID-19 faworyzowała kraje zdolne do szybkiej interwencji państwowej - niekoniecznie te z najwyższym EFW. Nie rozstrzygamy, która z tych interpretacji jest trafna - dane na to nie pozwalają.

Należy pamiętać, że EFW mierzy wolność gospodarczą, nie *stricte* jakość instytucji. Warto się zastanowić, czy indeks zaprojektowany w duchu anglosaskiego modelu gospodarczego jest właściwym narzędziem do badania 160 krajów - zwłaszcza gdy część najszybciej rosnących gospodarek świata konsekwentnie nie stosuje się do jego zaleceń. Góes w swojej pracy testował odporność wyników poprzez zastosowanie Corruption Perception Index (CPI) jako proxy - jednak ten wskaźnik również jest zachodnio-centryczny. Trudno obiektywnie dobrać miarę godną globalistycznej percepcji świata. Zresztą - w badaniu Góesa (2016, s. 90): „When using the CPI as the proxy [...] is also positive and statistically significant” - czyli problem nie leży w wyborze między EFW a CPI - trzeba drążyć dalej.

Praca ma kilka ograniczeń, które należy mieć na uwadze. Nie jest to dokładna replikacja - nie odtworzyliśmy próby N = 119 Góesa. Swoją drogą jest to niemożliwe do osiągnięcia nawet na podstawie materiałów autora dostępnych na GitHubie, ponieważ w udostępnionym na platformie pliku mamy do czynienia ze zbalansowaną próbą N = 142 krajów. Oprócz tego żaden z badanych okresów nie przechodzi jednocześnie testów AR(2) i Sargana. Nie raportujemy FEVD, choć Góes też tego nie robił. Mimo tych zastrzeżeń, formuła panelu VAR dobrze nadaje się do badania wpływu instytucji na wzrost - i warto je powtórzyć z miarą, która nie zaczyna od założenia że mniejszy rząd oznacza lepsze instytucje.

Bibliografia

Acemoglu Daron, Johnson Simon, Robinson James A., *The Colonial Origins of Comparative Development: An Empirical Investigation*, American Economic Review, 91(5), s. 1369-1401, 2001.

Fraser Institute, *Economic Freedom of the World: 2025 Annual Report*, Fraser Institute, Vancouver 2025, efotw.org.

Góes Carlos, *Institutions and Growth: A GMM/IV Panel VAR Approach*, IMF Working Paper 15/174, Washington 2015.

Góes Carlos, *Institutions and Growth: A GMM/IV Panel VAR approach*, Economics Letters, 138, s. 85-91, 2016.

Lucas Robert E., *On the Mechanics of Economic Development*, Journal of Monetary Economics, 22(1), s. 3-42, 1988.

North Douglass C., *Institutions, Institutional Change and Economic Performance*, Cambridge University Press, Cambridge 1990.

Solow Robert M., *A Contribution to the Theory of Economic Growth*, Quarterly Journal of Economics, 70(1), s. 65-94, 1956.

World Bank, *World Development Indicators*, Washington 2025, databank.worldbank.org.

Kraje użyte w części replikacyjnej 2000-2012 (N=157)

AGO Angola, ALB Albania, ARE Zjednoczone Emiraty Arabskie, ARG Argentyna, ARM Armenia, AUS Australia, AUT Austria, AZE Azerbejdżan, BDI Burundi, BEL Belgia, BEN Benin, BFA Burkina Faso, BGD Bangladesz, BGR Bułgaria, BHR Bahrajn, BHS Bahamy, BIH Bośnia i Hercegowina, BLR Białoruś, BLZ Belize, BOL Boliwia, BRA Brazylia, BRB Barbados, BTN Bhutan, BWA Botswana, CAF Rep. Środkowoafrykańska, CAN Kanada, CHE Szwajcaria, CHL Chile, CHN Chiny, CIV Wybrzeże Kości Słoniowej, CMR Kamerun, COD DR Kongo, COG Rep. Kongo, COL Kolumbia, CPV Cabo Verde, CRI Kostaryka, CYP Cypr, CZE Czechy, DEU Niemcy, DNK Dania, DOM Rep. Dominikańska, DZA Algieria, ECU Ekwador, EGY Egipt, ESP Hiszpania, EST Estonia, ETH Etiopia, FIN Finlandia, FJI Fidżi, FRA Francja, GAB Gabon, GBR Wielka Brytania, GEO Gruzja, GHA Ghana, GIN Gwinea, GMB Gambia, GNB Gwinea Bissau, GRC Grecja, GTM Gwatemala, GUY Gujana, HKG Hongkong, HND Honduras, HRV Chorwacja, HTI Haiti, HUN Węgry, IDN Indonezja, IND Indie, IRL Irlandia, IRN Iran, IRQ Irak, ISL Islandia, ISR Izrael, ITA Włochy, JAM Jamajka, JOR Jordania, JPN Japonia, KAZ Kazachstan, KEN Kenia, KGZ Kirgistan, KHM Kambodża, KOR Korea Północna, KWT Kuwejt, LAO Laos, LBN Liban, LBR Liberia, LKA Sri Lanka, LSO Lesotho, LTU Litwa, LUX Luksemburg, LVA Łotwa, MAR Maroko, MDA Mołdawia, MDG Madagaskar, MEX Meksyk, MKD Macedonia Północna, MLI Mali, MLT Malta, MMR Mjanma, MNE Czarnogóra, MNG Mongolia, MOZ Mozambik, MRT Mauretania, MUS Mauritius, MWI Malawi, MYS Malezja, NAM Namibia, NER Niger, NGA Nigeria, NIC Nikaragua, NLD Holandia, NOR Norwegia, NPL Nepal, NZL Nowa Zelandia, OMN Oman, PAK Pakistan, PAN Panama, PER Peru, PHL Filipiny, PNG Papua-Nowa Gwinea, POL Polska, PRT Portugalia, PRY Paragwaj, QAT Katar, ROU Rumunia, RUS Rosja, RWA Rwanda, SAU Arabia Saudyjska, SDN Sudan, SEN Senegal, SGP Singapur, SLE Sierra Leone, SLV Salwador, SRB Serbia, SVK Słowacja, SVN Słowenia, SWE Szwecja, SWZ Eswatini, SYC Seszele, SYR Syria, TCD Czad, TGO Togo, THA Tajlandia, TJK Tadżykistan, TTO Trynidad i Tobago, TUN Tunezja, TUR Turcja, TZA Tanzania, UGA Uganda, UKR Ukraina, URY Urugwaj, USA Stany Zjednoczone, VEN Wenezuela, VNM Wietnam, YEM Jemen, ZAF RPA, ZMB Zambia, ZWE Zimbabwe.